# Lab 1 - Report

Student ID: 518021910269Student Name: 胡昊源

• Date: 2020.6.1

#### 实验报告中,应该包含以下方面的内容:

- 对代码框架的分析;
- 实验要求完成的内容, 你的解决思路;
- 解析你的核心代码。

# Part I: Map/Reduce input and output

## 1、架构简介

Part I 中,我们需要修改 common\_map.go 、common\_reduce.go 中的 doMap() 、doReduce(),其代码所对应的架构如下图所示

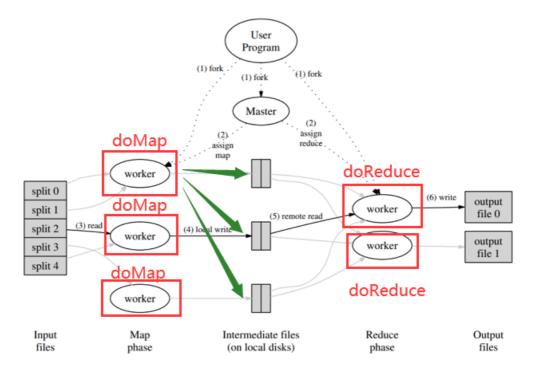


Figure 1: Execution overview

### 2、解决思路

doMap() 是每一个 Map Phase 中的 woker 需要调用的函数, 其功能大致为:

- (1) 读入分割后的文件 split\_i;
- (2) 调用自定义的映射函数 mapF() 将文件内容转换成相应的键值对 KeyValuePairs;
- (2) 将键值对以 JSON 格式写入到中间文件中,供 Reduce phase 的 woker 读取;

doReduce() 是每一个 Reduce Phase 中的 woker 需要调用的函数, 其功能大致为:

- (1) 读入 doMap()产生的中间文件,将 JSON 格式转化为 map 键值对;
- (2) 根据 key 做排序;
- (3) 调用 reduceF() 产生输出内容;
- (4) 将内容通过 encoder 写入至输出文件中;

#### 3、核心代码

实现 doMap(), 具体思路如下:

```
// Call mapF function to get keyValue Pairs
keyValuePairs := mapF(inFile, string(contents))
// Create multiple encoders to encode keyValue Pairs into JSON
var interFiles [] *os.File = make([] *os.File, nReduce)
var encoders [] *json.Encoder = make([] *json.Encoder, nReduce)
for i := 0; i < nReduce; i++ {
    // Map encoders with files
    interFileName := reduceName(jobName,mapTask,i)
    interFiles[i],err = os.Create(interFileName)
    if err != nil {
        log.Fatal(err)
    }
    defer interFiles[i].Close()
    encoders[i] = json.NewEncoder(interFiles[i])
    if err != nil {
        log.Fatal(err)
}
// Distribute tasks to encoders
for _ , keyValueIt := range keyValuePairs {
    hashKey := int(ihash(keyValueIt.Key)) % nReduce
    err := encoders[hashKey].Encode(&keyValueIt)
    if err != nil {
        log.Fatal("common_map.go: doMap encoders encode error",err)
    }
}
```

实现 doReduce(), 具体思路如下:

```
// Read internal file and change JSON contents into keyValue pairs
keyValuePairs := make(map[string][]string)
for i := 0; i < nMap; i++ {
    // Open the corresponding file
    fileName := reduceName(jobName, i, reduceTask)
    file, err := os.Open(fileName)
    if err != nil {
        log.Fatal("doReduce1: ", err)
    }
}</pre>
```

```
decoder := json.NewDecoder(file)
       for {
           var keyValueIt KeyValue
           err = decoder.Decode(&keyValueIt)
           if err != nil {
               break
           }
            _, exist := keyValuePairs[keyValueIt.Key]
           if !exist {
                keyValuePairs[keyValueIt.Key] = []string{}
           keyValuePairs[keyValueIt.Key] =
append(keyValuePairs[keyValueIt.Key], keyValueIt.Value)
       file.Close()
   }
   // Construct a key slice
   var keys []string
   for k := range keyValuePairs {
       keys = append(keys, k)
   }
   // Sort the slice
   sort.Strings(keys)
   // Create the output file
   outPutFileName := mergeName(jobName, reduceTask)
   outPutFile, err := os.Create(outPutFileName)
   if err != nil {
       log.Fatal("doReduce2: ceate ", err)
   }
   // Encode the output contents into JSON form
   encoder := json.NewEncoder(outPutFile)
   for _, keyIt := range keys {
        content := reduceF(keyIt, keyValuePairs[keyIt])
       encoder.Encode(KeyValue{keyIt, content})
   }
   outPutFile.Close()
```

# Part II: Single-worker word count

# 1、架构简介

Part II 中,我们需要实现 main/wc.go 中的 mapF()、reduceF(),其代码所对应的架构如下图所示

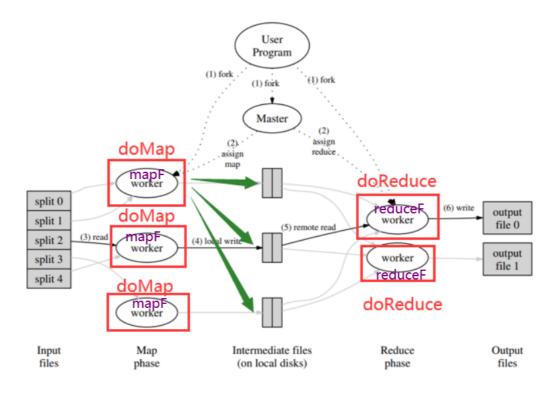


Figure 1: Execution overview

### 2、解决思路

mapF() 是每一个 Map Phase 中的 woker 实际处理文件内容的函数,在 Part II 的要求下,我们需要统计每个单词的出现的次数。

### 我的解决思路为:

- (1) 规定划分单词的规则 function f;
- (2) 依照 function f,调用 string.FieldsFunc() 函数,对内容进行划分,生成一个由 string 组成的 slice;
- (3) 将 slice 中的每个 string,重新组织成 key-value 的形式,这里我设定 key 为具体的单词,value 为出现的次数(这里均为 1);

例如,我们有内容 apple apple blue,那么 mapF() 后的返回值为 {"apple","1"}、{"apple","1"}、{"blue","1"}。

reduceF() 是每一个 Reduce Phase 中的 woker 实际处理文件内容的函数,在 Part II 的要求下,我们需要把中间文件中的键值对重新整合输出。

### 我的解决思路为:

(1) 直接返回传入的 string slice 的长度;

例如我们有内容 apple apple blue,那么 mapF() 后的返回值为 {"apple","1"}、 {"apple","1"}、 {"blue", "1"},此时我们调用 reduceF("apple", []string{"1","1"}),那么我们如果要统计 apple 出现了多少次,直接计算传入的 slice 的长度即可。

#### 3、核心代码

实现 mapF(), 具体思路如下:

```
// Splict contents into slices
f := func(c rune) bool {
    return !unicode.IsLetter(c) && !unicode.IsNumber(c)
}
var stringSlice []string = strings.FieldsFunc(contents, f)

// Produce KeyValue type result
var result []mapreduce.KeyValue
for _, stringSliceIt := range stringSlice {
    keyValuePair := mapreduce.KeyValue{stringSliceIt, "1"}
    result = append(result, keyValuePair)
}

return result
```

实现 reduceF(), 具体思路如下:

```
// Your code here (Part II).
var result string = strconv.Itoa(len(values))
return result
```

# Part III: Distributing MapReduce tasks

# 1、架构简介

Part III 中,我们需要实现 mapreduce/schedule.go 中的 schedule() ,其代码所对应的架构如下图所示

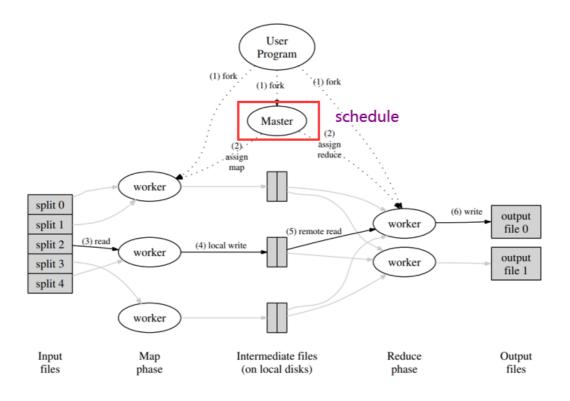


Figure 1: Execution overview

## 2、解决思路

schedule() 是 master 节点所调用的函数负责根据 phase,向已注册的 worker 通过 RPC 发放 map/reduce 任务。

### 我的解决思路为:

- (1) 我们需要判断 phase,从而判断要分配给 worker 的任务类型,为相关参数赋值;
- (2) 我们需要创建一个 waitGroup, 来判断所有任务的完成情况;
- (3) 对于每个任务,我们需要填充其任务参数,调用 call() 函数,通过 RPC 发布给对应的 worker(这里我们需要并行执行);
- (4) 当任务完成后,我们需要调用 waitGroup.done(),来表示任务已经完成,同时我们也要把当前空闲的 worker 重新加入到 registerChan 注册队列中;
- (5) 我们的主线程会卡在 waitGroup.wait() 处,直到所有任务完成, schedule 结束;

#### 3、核心代码

实现 schedule(), 具体思路如下:

```
var ntasks int
var n_other int // number of inputs (for reduce) or outputs (for map)
switch phase {
    case mapPhase:
        ntasks = len(mapFiles)
        n_other = nReduce
    case reducePhase:
        ntasks = nReduce
        n_other = len(mapFiles)
}

fmt.Printf("Schedule: %v %v tasks (%d I/Os)\n", ntasks, phase, n_other)
```

```
// All ntasks tasks have to be scheduled on workers. Once all tasks
    // have completed successfully, schedule() should return.
   // Your code here (Part III, Part IV).
    // By using channel, realize the concurrent RPC task
    var wg sync.WaitGroup
    for i := 0; i < ntasks; i++ {
        wg.Add(1)
        go func(number int) {
            // Confige the arguments
            args := DoTaskArgs{jobName, mapFiles[number], phase, number,
n_other}
            // Confige and invocate the RPC
            var worker string
            reply := new(struct{})
            ok := false
            for ok != true {
                worker = <- registerChan</pre>
                ok = call(worker, "worker.DoTask", args, reply)
            }
            wg.Done()
            registerChan <- worker
        }(i)
    }
    // Stuck until all the tasks are finished
    wg.Wait()
    fmt.Printf("Schedule: %v done\n", phase)
```

# Part IV: Handling worker failures

## 1、架构简介

Part IV 中,我们需要优化 mapreduce/schedule.go 中的 schedule() ,其代码所对应的架构如下图所示

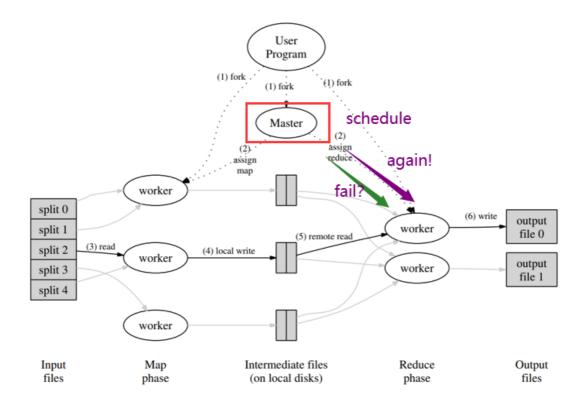


Figure 1: Execution overview

#### 2、解决思路

我们需要解决 schedule() 函数的容错问题,错误可能出现在多个地方: RPC 超时、worker 执行错误等。但是由于 mapreduce 的架构设计,我们的每一个工作都是幂等的,也就是说,我们即便重复进行多次操作,最后的结果也是一样的。

## 我的解决思路为:

(1) 对于一个幂等的操作来说,如果出现错误,我们只需要重新让它做一遍,直到做对就好;

# 3、核心代码

优化 schedule(), 具体思路如下:

```
go func(number int) {
    // Confige the arguments
    args := DoTaskArgs{jobName, mapFiles[number], phase, number, n_other}

    // Confige and invocate the RPC
    var worker string
    reply := new(struct{})
    ok := false
    for ok != true {
        worker = <- registerChan
        ok = call(worker, "worker.DoTask", args, reply)
    }
    wg.Done()
    registerChan <- worker
}(i)</pre>
```

# Part V: Inverted index generation (OPTIONAL)

## 1、架构简介

Part V 中,我们需要实现 main/ii.go 中的 mapF()、reduceF(),其代码所对应的架构如下图所示

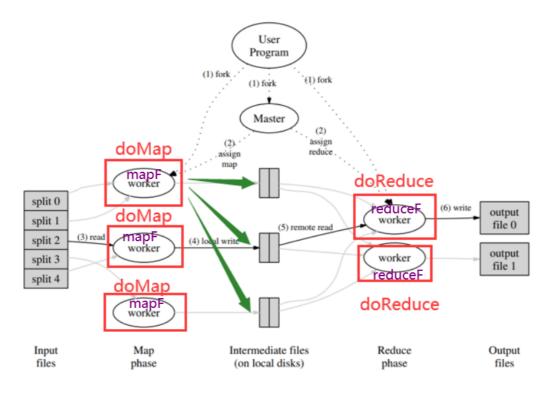


Figure 1: Execution overview

#### 2、解决思路

Part V 的需求和 Part II 十分类似,但是Part V 不但需要找出每个单词在多少文件中出现,还需要找到包含这个单词的文件名。

通过修改 mapF()、reduceF() 就能够实现这个需求。

对于 mapF(), 我的解决思路为:

- (1) 按照需求,实现 function f 来划分文件内容,得到存有每个单词的 string slice;
- (2) 我们使用 map 类型,在 go 语言下实现一个集合,其键 key 为单词,其值 value 为文件名;
- (3) 把 map 类型重新组织为 keyValue slice 返回;

例如,我们在 "a.txt" 文件下有单词 apple apple blue,那么我们在 mapF() 后,得到键值对:{"apple", "a.txt"}、{"blue", "a.txt"}。

对于 reduceF(), 我的解决思路为:

- (1) 通过统计传入的 slice values 的长度,得到包含该单词的文件数;
- (2) 通过 sort 对 values 进行排序;
- (3) 组织输出格式,将所有的 values 输出;

例如我们有内容 apple apple blue,那么 mapF() 后的返回值为 {"apple","a.txt"}、{"blue","a.txt"},此时我们调用 reduceF("apple", []string{"a.txt"}),根据上述思路,就可以输出正确结果。

#### 3、核心代码

实现 mapF(), 具体思路如下:

```
// Your code here (Part V).
// Splict contents into slices
f := func(c rune) bool {
    return !unicode.IsLetter(c)
var words []string = strings.FieldsFunc(value, f)
// Realize a set
var wordToFilename map[string]string = make(map[string]string)
for _, wordsIt := range words {
   // Whether the key is existed
    _, ok := wordToFilename[wordsIt]
   if !ok {
        wordToFilename[wordsIt] = document
    }
}
// Produce KeyValue type result
for wordsIt, fileNameIt := range wordToFilename {
    keyValuePair := mapreduce.KeyValue{wordsIt, fileNameIt}
    res = append(res, keyValuePair)
return
```

### 实现 reduceF(), 具体思路如下:

```
// Your code here (Part V).
// Get the number of occurrences for each word
var numCounter string = strconv.Itoa(len(values))

// Sort the fileNames
var fileNames []string = values
sort.Strings(fileNames)

// Splice output string
var result string = numCounter + " "
for _, fileNameIt := range fileNames {
    result = result + fileNameIt + ","
}

// Delete the last ','
result = result[:len(result)-1]
return result
```